# НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ

«Київський політехнічний інститут імені Ігоря Сікорського» Факультет інформатики та обчислювальної техніки Кафедра інформатики та програмної інженерії

> Звіт до лабораторної роботи №1 з дисципліни «Мультипарадигменне програмування»

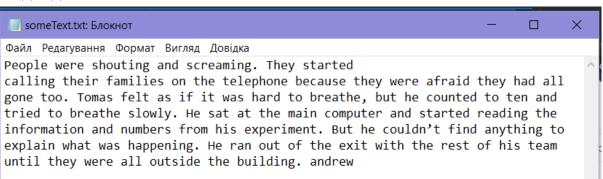
Перевірив Очеретяний О.К. "14" лютого 2022 р. Виконала Студент групи IT-02 Рожкован В.С.

### Завдання 1:

Обчислювальна задача тут тривіальна: для текстового файлу ми хочемо відобразити N (наприклад, 25) найчастіших слів і відповідну частоту їх повторення, упорядковано за зменшенням. Слід обов'язково нормалізувати використання великих літер і ігнорувати стоп-слова, як «the», «for» тощо. Щоб все було просто, ми не піклуємося про порядок слів з однаковою частотою повторень. Ця обчислювальна задача відома як term frequency.

Під час виконання завдання, перш за все, необхідно було відкрити файл і прочитати з нього дані. Потім регуляркою (\w+) розділила текст на слова і записала його до вектора, водночає перевела їх в нижній регістр. Визначила стоп-слова і відсіяла їх з одержаного списку слів. Ті слова, які залишились додала в мап, визначивши їх кількість, відсортувала їх в алфавітному порядку і вивела.

#### Вхідні дані:



#### Вихідні дані:

```
he : 4
they: 4
were : 3
all : 2
breathe : 2
but : 2
his : 2
of : 2
started : 2
was : 2
afraid : 1
andrew : 1
anything: 1
as : 1
because : 1
building : 1
calling : 1
computer : 1
couldn : 1
counted: 1
exit : 1
experiment : 1
explain : 1
families : 1
```

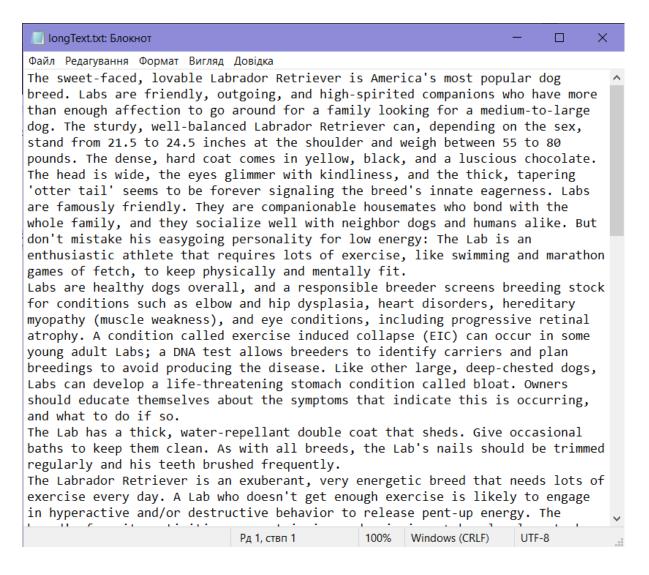
# Завдання 2:

Тепер, нам потрібно виконати задачу, що називається словниковим індексуванням. Для текстового файлу виведіть усі слова в алфавітному порядку разом із номерами сторінок, на яких Ці слова знаходяться. Ігноруйте всі слова, які зустрічаються більше 100 разів. Припустимо, що сторінка являє собою послідовність із 45 рядків.

Виконуючи друге завдання, спочатку відкрила файл для читання та вказала, що одна сторінка це 45 рядків. Потім почала зчитувати файл порядково (якщо рядок пустий - він пропускається). У кожному рядку за допомогою вищезгаданої регулярки розділила текст на слова та перевела слова у нижній регістр. Розділенні слова додавала в хеш-мап перевіряючи їх на унікальність та записуючи номер сторінки на якій вони зустрічались. Потім, якщо слово зустрічалось більше 100 разів, видаляла його з хеш-мапа. У с++ ключі в хеш-мапі записуються в алфавітному

порядку, тому це не потрібно було корегувати. В кінці вивела усе в консоль.

#### Вхідні дані:



## Вихідні дані:

```
5:1
55 : 1
7 : 5
80 : 1
a : 1 2 3 4 5 6 7 8 9
about : 2 6
accordingly : 8
activities: 45
adaptability: 9
addition: 8
adjusted : 5
adult : 2 5 6
affection : 1
age : 6
ages : 5
agility : 4
aid : 6
aids : 9
akc : 10
alike : 1
all : 3 6
allows : 2
also : 4
america : 1 10
an:1469
ancestral : 8
and: 12345678910
animal : 9
any : 5 6
appeals : 9
```